

1 Task 1: 基于 ImageNet 预训练卷积神经网络的 102 类花卉识别

本实验完成 102 类花卉图像分类任务。Baseline 采用 ResNet-18，并将最后的全连接分类层替换为 102 维输出层。训练时使用 ImageNet 预训练参数初始化主干网络，新的分类层随机初始化；为了避免破坏预训练特征，主干网络使用较小学习率，分类层使用较大学习率。评价指标采用测试集准确率，即实验记录中的 `test_acc`。实验重点比较三类因素：学习率设置、注意力机制以及是否使用预训练。

实验使用 Oxford 102 Category Flower Dataset 作为图像分类数据集，任务目标是将输入花卉图像分类到 102 个类别之一，具体实验中设置训练集、验证集、测试集数据个数分别为 6149,1020,1020。

1.1 实验设置

项目	设置
数据集	102 Category Flower Dataset，包含 102 个花卉类别；按照代码中的训练集、验证集和测试集划分进行训练与评估。
输入处理	图像 <code>resize / crop</code> 后输入网络，并进行常规归一化处理。
Baseline	ResNet-18，将原始 ImageNet 分类头替换为 102 类分类头。
注意力模型	在 ResNet-18 基础上分别加入 SE-block 与 CBAM 模块。
训练轮次	主要实验为 20 epochs；额外进行了 40 epochs 的训练轮次实验。
Batch size	64。
损失函数	Cross Entropy Loss。
优化器	SGD（带 momentum 的 SGD）
学习率	主干网络学习率为 <code>backbone_lr</code> ，分类层学习率为 <code>fc_lr</code> 。
评价指标	Accuracy，最终结果采用 <code>test_acc</code> 。

实验结果汇总

编号	实验内容	模型	预训练	Epoch	主干 LR	分类头 LR	Test Acc
H1	Baseline	resnet18	是	20	1×10^{-3}	1×10^{-2}	94.80%
H2	学习率实验	resnet18	是	20	5×10^{-4}	5×10^{-3}	93.92%
H3	学习率实验	resnet18	是	20	1×10^{-4}	1×10^{-3}	75.00%
H4	学习率实验	resnet18	是	20	5×10^{-3}	5×10^{-2}	96.18%
H5	训练轮次实验	resnet18	是	40	1×10^{-3}	1×10^{-2}	95.88%
H6	无预训练	resnet18	否	20	1×10^{-3}	1×10^{-2}	43.92%
H7	SE 模块	resnet18_se	是	20	5×10^{-3}	5×10^{-2}	96.57%
H8	CBAM 模块	resnet18_cbam	是	20	5×10^{-3}	5×10^{-2}	96.67%

从总体结果看，最佳模型为加入 CBAM 注意力机制的 ResNet-18，测试准确率达到 **96.67%**。相比原始 Baseline 的 94.80%，准确率提升了 1.87 个百分点；相比同学习率下未加入注意力机制的 ResNet-18，仍提升了 0.49 个百分点。预训练带来的提升最明显，使用预训练时准确率为 94.80%，不使用预训练时仅为 43.92%。

训练过程可视化




图 1: wandb 记录的训练过程曲线，包括训练集 loss、训练集 accuracy、验证集 loss 与验证集 accuracy。

从 wandb 曲线可以看到，模型在前几个 epoch 内 loss 快速下降，accuracy 快速上升，随后逐渐进入稳定阶段。训练集与验证集曲线趋势基本一致，说明模型能够正常收敛，且没有出

现明显的训练崩溃。后期验证集准确率趋于平稳，说明继续训练带来的收益有限。

1.2 不同学习率对比




图 2: 不同学习率组合下的模型训练与验证表现。

学习率对模型收敛速度和最终精度影响明显。当主干学习率为 1×10^{-4} 、分类头学习率为 1×10^{-3} 时，模型收敛非常慢，训练集和验证集 loss 长时间保持较高水平，最终准确率仅为 75.00%，表现出明显欠拟合。Baseline 使用 1×10^{-3} 与 1×10^{-2} 时可以稳定收敛，准确率达到 94.80%。进一步提高到 5×10^{-3} 与 5×10^{-2} 后，模型仍能保持稳定，并取得 96.18% 的准确率，是学习率实验中的最优组合。说明在本任务中，适当增大学习率能够加快分类头和高层特征的适配速度。

1.3 注意力机制对比




图 3: ResNet-18、ResNet-18+SE 与 ResNet-18+CBAM 的对比。

在相同预训练和学习率设置下，加入注意力机制后模型性能略有提升。原始 ResNet-18 的准确率为 96.18%，加入 SE 模块后提升至 96.57%，加入 CBAM 后进一步提升至 96.67%。SE 模块主要通过通道注意力重新分配不同特征通道的重要性，CBAM 同时引入通道注意力和空间注意力，因此能够更好地关注花瓣纹理、颜色区域和主体位置。由于 ResNet-18 Baseline 本身已经具有较强的特征提取能力，所以注意力模块带来的提升幅度不大，但结果稳定优于原始模型。

1.4 是否使用预训练对比




图 4: 使用 ImageNet 预训练与随机初始化训练的对比。

预训练是本实验中影响最大的因素。使用 ImageNet 预训练参数时，模型在前几个 epoch 内迅速收敛，验证集准确率很快超过 90%，最终达到 94.80%。而不使用预训练、从随机初始化开始训练时，训练集和验证集 loss 下降缓慢，最终准确率只有 43.92%。这说明 102 类花卉数据集规模相对有限，如果完全从零训练 ResNet-18，模型难以在 20 个 epoch 内学习到稳定的底层纹理、边缘和形状特征；ImageNet 预训练提供了通用视觉特征，使模型只需在花卉分类任务上进行特征迁移和分类头适配，因此泛化效果显著更好。

1.5 结论

本实验完成了基于 ResNet-18 的 102 类花卉识别，并围绕学习率、注意力机制和预训练进行了对比分析。实验结果表明，分组学习率能够有效提升微调效果，其中 5×10^{-3} 与 5×10^{-2} 的组合表现最好；SE 和 CBAM 注意力机制均能进一步提升准确率，其中 CBAM 取得最高的 96.67%；预训练对模型性能影响最为关键，不使用预训练时准确率下降到 43.92%。综合来看，最佳方案是使用 ImageNet 预训练的 ResNet-18，并在较优学习率设置下加入 CBAM 注意力机制。